

Taller 2

Carlos Méndez y Diego Sarmiento

Técnicas de Aprendizaje de Máquina

Omar Palacio

18 de octubre de 2026

1. **Comprensión del Dataset**

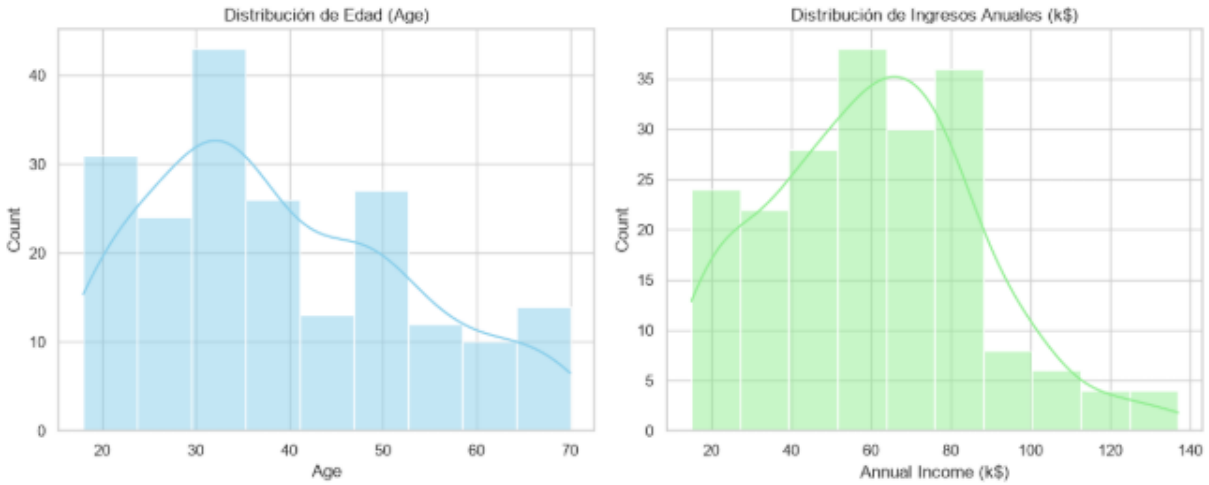
Para la realización de este taller, se debe tener en cuenta el contexto de negocio en el que se trabaja. En este caso, se trabajará con datos provenientes de un comercio cuyo objetivo es identificar posibles clientes objetivo a quienes se les puedan aplicar estrategias según su categoría asignada. Estos datos se recolectan mediante tarjetas de membresía, y el objetivo final es segmentar a los clientes mediante modelos de clustering como K-Means.

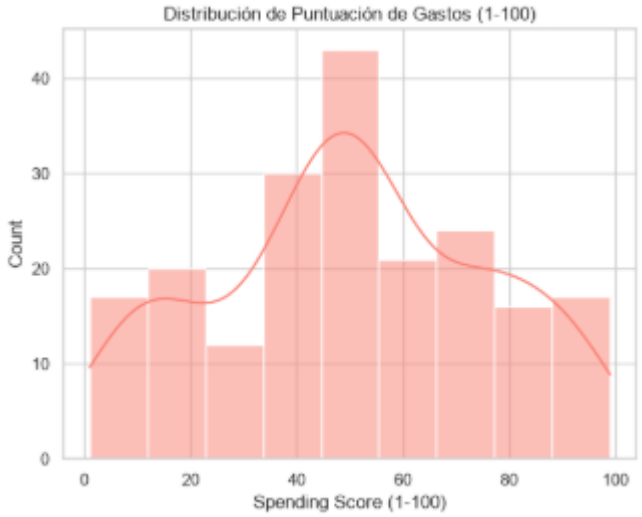
Tipo de Datos

- **CustomerID (entero):** Identificador único asignado a cada cliente.
- **Gender (cadena de caracteres):** Género del cliente.
- **Age (entero):** Edad del cliente.
- **Annual Income (k$) (entero):** Corresponde al ingreso anual de cada cliente.
- **Spending Score (1-100) (entero):** Puntaje asignado por el comercio teniendo en cuenta los comportamientos y el gasto del cliente.

Análisis Gráfico:

Distribuciones:



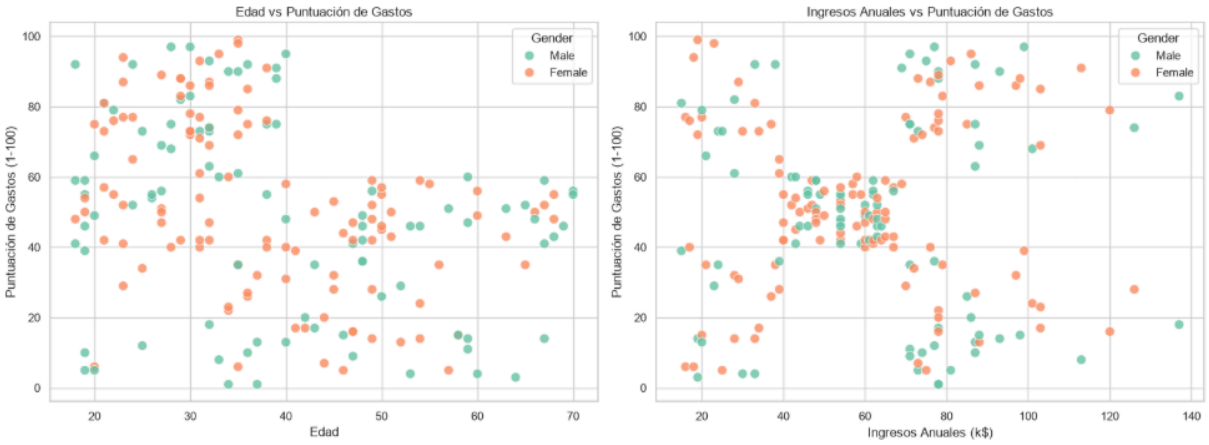


Dadas las distribuciones, es esencial señalar las escalas y los inicios que estas presentan, por ejemplo, la gráfica de edad presenta una amplia masa de registros a partir de los 20 años hasta los 50, teniendo su punto máximo en el rango de 30-35 años. A partir de los 50, la cantidad de valores disminuye considerablemente.

Siguiendo con la distribución de ingresos anuales, se logra identificar una fuerte caída en la cantidad de personas que ganan más de 80 mil dólares al año, disminuyendo el valor a medida que sube más el ingreso. Nuevamente, los primeros dos tercios de la gráfica son los que concentran la mayor cantidad de datos.

Por último, la gráfica de puntuación de gastos indica qué tanto gasta la persona en el comercio, lo que quiere decir que se encuentra en un punto balanceado si comparamos los valores más extremos (0 y 100), sin embargo, la gran mayoría de clientes se encuentran en un valor intermedio (50).

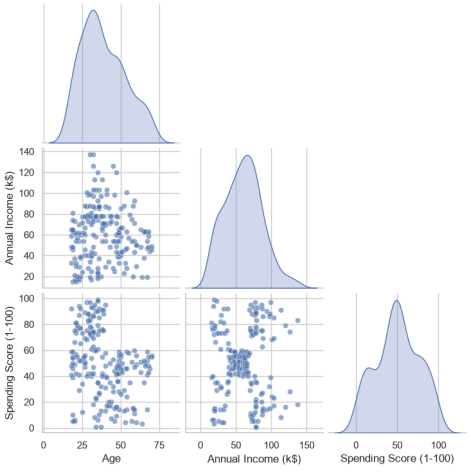
Dispersión:



Este gráfico es de gran utilidad teniendo en cuenta el algoritmo a utilizar y el objetivo de negocio. En la primera gráfica, se pueden identificar dos grupos, uno más claro que el otro, situado en la parte superior izquierda de la gráfica de Edad vs Puntuación de gastos, lo cual puede indicar que las personas de menor edad tienden a gastar más y viceversa.

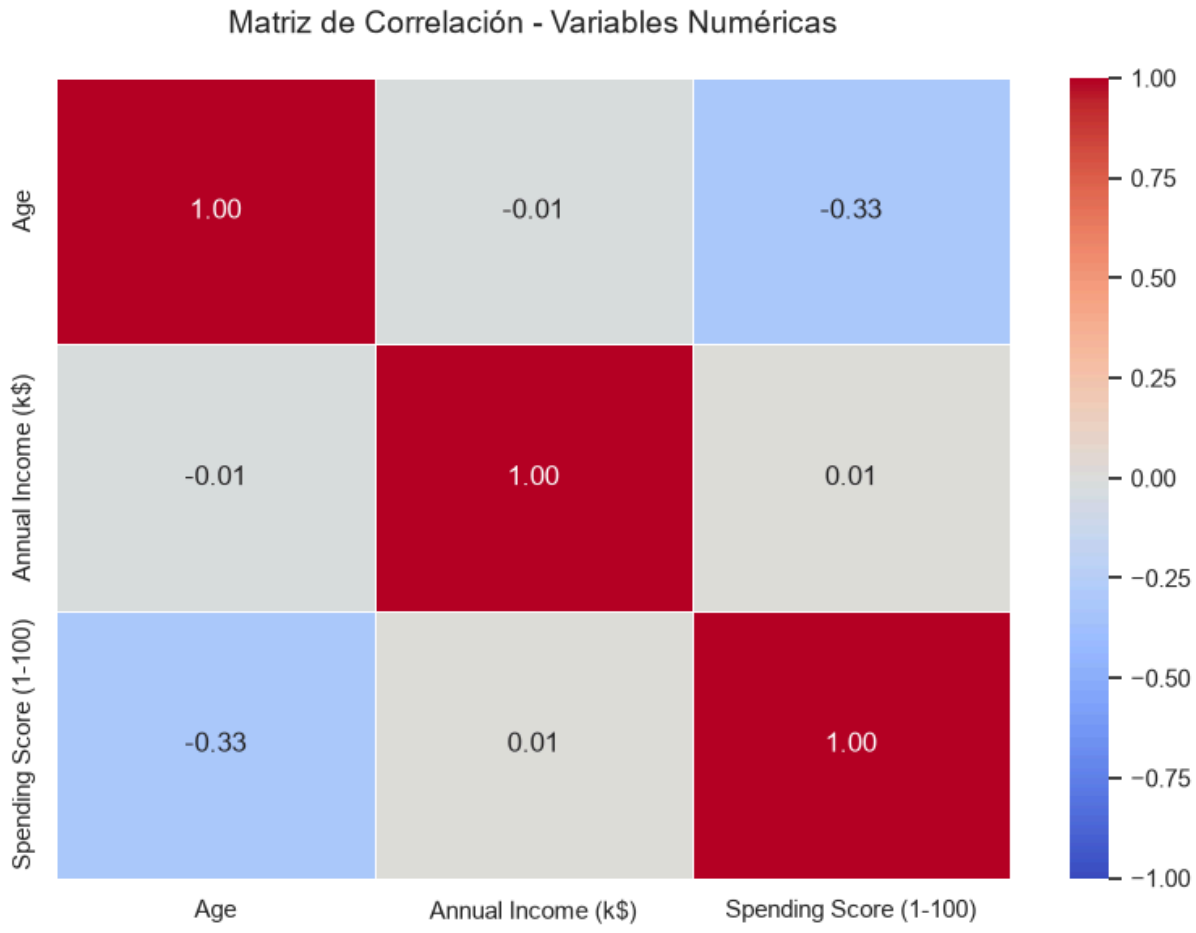
Por otro lado, el gráfico de ingresos anuales vs. puntuación de gastos tiene un comportamiento más interesante, pues no existe esta tendencia a "entre mayor ingreso, mayor gasto", sino que hay más variabilidad en los registros; sin embargo, existen 5 grupos aparentemente sencillos de identificar, formando una "X".

Pairplot:



Por último, se presentan los gráficos de todas las variables entre sí, se logra denotar en primer lugar el grupo con forma de X aún más claro, por otro lado, el gráfico de spending score vs age muestra cierto comportamiento interesante de los datos, formando cierta L con una cantidad considerable de datos en la parte inferior, nuevamente, la tendencia aparente en cuanto al gasto y la edad es que se gasta más cuanto más joven sea, sin embargo los valores de 75 años tampoco presentan valores muy bajos hablando sobre la masa central de datos, también es prudente resaltar que aún así, existen ciertos outliers ubicados por debajo de la media.

Finalmente, la gráfica de anual income vs age presenta una alta variabilidad en los datos y no permite identificar grupos de forma intuitiva.



Se evidencia que no existe correlación entre las variables, excluyendo a age y spending score; sin embargo, hay muy poca correlación, lo cual es algo positivo para el k-means, que requiere que cada dimensión sea independiente.

2. **Limpieza de los datos**

Selección de variables:

- Customer ID: Inicialmente se decide eliminar la variable Customer ID, ya que simplemente es un identificador único para cada cliente, no entrega información valiosa a la hora de agrupar para conseguir información de etiquetas.
- Gender: Se decide eliminar también la variable de género por dos razones en específico, la primera siendo su falta de compatibilidad con el algoritmo K-means, al ser una variable binaria, confunde las distancias que se usan en la técnica, afectando los cálculos de los centroides, varianzas y demás. En segunda instancia, realmente no es de importancia para el caso estudiar el género del cliente; continuar con esta variable puede traer sesgo no deseado; además, K-Means, al ser un modelo que se enfoca principalmente en las distancias entre las observaciones, la variable de género no brindaría información valiosa al modelo.

Escalado de datos: Para el escalado de datos se decide avanzar con el StandardScaler, que estandariza las variables basándose en su media y varianza. Se concluyó que esta es la mejor opción para trabajar dado que en comparación con MinMaxScaler, esta no es sensible a datos atípicos, facilitando el proceso de escalado.

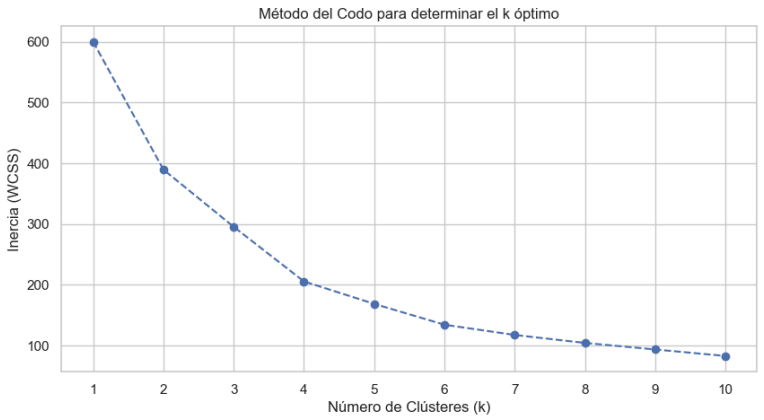
3. **Construcción del dataset**

En la interrogante sobre si dividir o no los datos en train y test, se decide que lo mejor es no dividir los datos. En un algoritmo como lo es K-means, es muy importante que, a la hora de implementar el modelo, se cuente con toda la información posible y, al separar los datos, lo único que ocurre es una pérdida de datos valiosos para las etiquetas. Aparte, una de las razones principales de la separación de datos en train-test es poder, mediante diferentes métricas, evaluar el desempeño del modelo; en este caso, eso no es necesario, ya que las métricas del modelo K-means miden la cohesión geométrica y la separación de los grupos.

Es por esto que para iniciar el proceso de modelado se usa la matriz final, incluyendo las variables de Age, annual income y Spending Score, todas escaladas con StandardScaler.

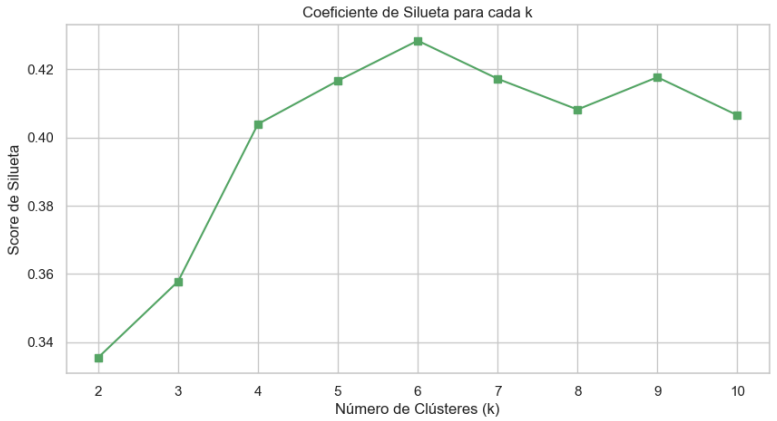
4. **Verificación de Resultados y Selección de K**

Método del codo:



Con este método, aunque quizá generalmente el punto de inflexión es más evidente y en este caso no tanto, se puede ver cómo en el clúster 5 el WCSS o la inercia tiene su equilibrio, dejando como buen candidato el k=5.

Coeficiente de Silueta:



Por otro lado, encontramos que usando el coeficiente de silueta, tenemos un candidato de clúster distinto pero no muy lejano. En este caso, dados los resultados, es recomendable usar k=6. Este resultado, aunque no demuestra un coeficiente de silueta muy alto (solo de 0.42), es el número de clústeres que demuestra buen agrupamiento de los datos, encontrando los clústeres lejos de los vecinos y muy cerca de los de su propio grupo.

5. Depuración y análisis del negocio

Tras realizar el modelo con 5 centroides y revertir la estandarización para la interpretabilidad, se llegó a los siguientes resultados:

Centroides en escala original:

	Age	Annual Income (k$)	Spending Score (1-100)
Cluster 0	46.250000	26.750000	18.350000
Cluster 1	25.185185	41.092593	62.240741
Cluster 2	32.875000	86.100000	81.525000
Cluster 3	39.871795	86.102564	19.358974
Cluster 4	55.638298	54.382979	48.851064

Esta tabla nos brinda información de los grupos creados por cada uno de los 5 centroides, teniendo en cuenta las distancias entre cada observación. Cada grupo

representa un tipo de cliente registrado, estos pueden denominarse de la siguiente manera:

- Cluster 0: Este cluster representa aquellas personas cercanas a la edad de 46 años, que tienen unos ingresos y gastos bajos
- Cluster 1: Este cluster representa a los clientes jóvenes que presentan unos ingresos medios y gastos medios altos
- Cluster 2: Representa a aquellas personas jóvenes que presentan ingresos y gastos altos.
- Cluster 3: Este cluster representa aquellas personas de 40 años cuyos ingresos son altos pero gastos bajos
- Cluster 4: Aquellas personas maduras que tienen gastos e ingresos medios

Dados los grupos anteriormente mencionados, se le sugiere al equipo de marketing dos enfoques:

Priorizar la fidelización de aquellos grupos que presentan gastos medios (clústeres 1 y 4), pues puede que sean los que representen un riesgo mayor dada la incertidumbre de compra

Enfocar sus campañas en el clúster 3, pues es donde hay mayor margen de mejora en cuanto al puntaje de gasto gracias a la cantidad de dinero que ganan anualmente; de esta manera, estos clientes se convertirán en actores activos en términos de ingresos para el comercio.

6. Comparación entre modelos

```
--- Comparación de Convergencia e Inercia ---
Init Aleatoria -> Inercia: 190.48 | Iteraciones: 6 | Tiempo: 0.0038s
Init K-Means++ -> Inercia: 169.89 | Iteraciones: 7 | Tiempo: 0.0044s
```

Para el análisis de ambos modelos se deben tener en cuenta principalmente los valores de la inercia y el tiempo de convergencia obtenidos. En primer lugar, la inercia (suma de errores cuadráticos entre clústeres) es la métrica que evalúa qué tan compactos están los grupos creados. El objetivo es minimizarla, lo que demuestra que utilizar la inicialización k-means++ es la mejor estrategia para este modelo. Al analizar el tiempo de convergencia, ocurre algo interesante: el método aleatorio obtiene un menor tiempo en comparación con k-means++. Sin embargo, esto no es un punto a favor, ya que el método aleatorio converge más rápido simplemente porque suele estancarse de forma prematura en un mínimo local, conformándose con una agrupación inicial deficiente. En conclusión, la inicialización k-means++ invierte una fracción de tiempo adicional al calcular distancias previas para ubicar estratégicamente los centroides. Esto garantiza minimizar la inercia de manera efectiva y lograr clústeres compactos, corrigiendo el estancamiento y la imprecisión propios de la inicialización puramente aleatoria.